PERANCANGAN SISTEM DETEKSI KEMIRIPAN SEMANTIK DOKUMEN SKRIPSI BERBASIS *FINE-TUNED* INDOBERT SIAMESE BI-ENCODER

A SEMANTIC SIMILARITY DETECTION SYSTEM FOR THESIS DOCUMENTS BASED ON FINE-TUNED INDOBERT SIAMESE BI-ENCODER

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat memperoleh gelar sarjana

Dari Program Studi S1 Informatika

Direktorat Kampus Surabaya

Universitas Telkom

Disusun oleh:

FIRSTYATAMA AUZAN FARHADI

1203220009

PROGRAM STUDI SARJANA INFORMATIKA

DIREKTORAT KAMPUS SURABAYA

UNIVERSITAS TELKOM

SURABAYA

2026

LEMBAR PENGESAHAN

TUGAS AKHIR

PERANCANGAN SISTEM DETEKSI KEMIRIPAN SEMANTIK DOKUMEN SKRIPSI BERBASIS *FINE-TUNED* INDOBERT SIAMESE BI-ENCODER

Telah disetujui dan disahkan untuk memenuhi sebagian syarat memperoleh gelar Sarjana pada Program Studi Informatika
Direktorat Kampus Surabaya
Universitas Telkom

Disusun oleh:
FIRSTYATAMA AUZAN FARHADI
1203220009

Surabaya, 10 Agustus 2026
Menyetujui,

1. **Alqis Rausanfita, S.Kom., M.kom.** (Pembimbing I)
   NIP. 22960060
2. **Dr. Tanzilal Mustaqim, S.Kom., M. Kom.** (Pembimbing II)
   NIP. 23980024
3. **Daud Muhajir, S.Kom., M.Kom.** (Penguji I)
   NIP. 23970024
4. **Affifah Mutiara Pertiwi, S.Kom., M.Cs.** (Penguji II)
   NIP. 25950039

Kaprodi Informatika

Rizky Fenaldo Maulana, S.Kom., M.Kom.
NIP. 25970012

LEMBAR PERNYATAAN ORISINALITAS



Nama	:	Firstyatama Auzan Farhadi
NIM	:	1203220009
Alamat	:	Jl. Kapas Madya 4N No.46, Tambaksari, Surabaya
No. Telp	:	088990011131
Email	:	auzan.tama@gmail.com

Menyatakan bahwa Tugas Akhir ini merupakan karya orisinal saya sendiri. Atas pernyataan ini, saya siap menanggung risiko atau sanksi yang dijatuhkan kepada saya apabila kemudian ditemukan adanya pelanggaran terhadap kejujuran akademik atau etika keilmuan dalam karya ini, atau ditemukan bukti yang menunjukkan ketidakaslian karya ini.

Surabaya, 10 Juni 2026

Firstyatama Auzan Farhadi

ABSTRAK

Kemajuan akses referensi digital meningkatkan risiko plagiarisme pada Bab II skripsi, terutama dalam bentuk parafrase dan perubahan struktur kalimat yang sulit dideteksi oleh metode *lexical matching* seperti n-gram karena metode tersebut hanya mengenali kemiripan pada tingkat kata, bukan makna. Penelitian ini bertujuan mengembangkan sistem deteksi kemiripan semantik berbasis *Fine-Tuned IndoBERT Siamese Bi-Encoder* untuk mengenali parafrase pada teks akademik panjang berbahasa Indonesia. Sistem dibangun dari 45 dokumen Bab II skripsi yang diekstraksi dari PDF, disegmentasi menggunakan *sliding window* berbasis *tokenizer* IndoBERT, lalu diuji pada tiga skenario *preprocessing* untuk mengevaluasi pengaruh *masking* sitasi dan referensi visual. Model di latih dengan arsitektur *Siamese Bi-Encoder* dan dievaluasi menggunakan *5-Fold Cross-validation* berbasis dokumen, serta divalidasi terhadap anotasi manusia untuk mengukur reliabilitas label. Hasil pengujian menunjukkan reliabilitas anotasi yang sangat baik dengan Krippendorff's Alpha sebesar 0,8070 dan ICC(A,k) sebesar 0,9548. Skenario data dengan *masking* sitasi dan referensi menghasilkan korelasi terbaik dengan Pearson 0,9139 dan Spearman 0,9231, sedangkan skenario data dengan *masking* sitasi menghasilkan kesalahan prediksi terendah dengan RMSE 0,1608 dan MAE 0,1137. Evaluasi setiap zona menunjukkan akurasi 99% pada zona kemiripan tinggi dan sedang, namun menurun hingga 43-63% pada zona rendah dan negatif, dengan akurasi diagonal confusion matrix terendah 20,7-25,1%.

Kata Kunci: deteksi kemiripan semantik, IndoBERT, parafrase, plagiarisme akademik, *Siamese* Bi-Encoder.

ABSTRACT

Digital reference accessibility has increased the risk of plagiarism in undergraduate thesis Chapter II, particularly through paraphrasing and sentence-structure alteration that lexical-matching methods such as n-gram struggle to detect, since these methods only recognize word-level similarity rather than meaning. This study aims to develop a semantic similarity detection system based on a Fine-Tuned IndoBERT Siamese Bi-Encoder to recognize paraphrasing in long-form Indonesian academic text. The system was built from 45 thesis Chapter II documents extracted from PDF, segmented using an IndoBERT tokenizer-based sliding window, and tested across three preprocessing scenarios to evaluate the effect of citation and visual-reference masking. The model was trained using a Siamese Bi-Encoder architecture and evaluated using document-based 5-Fold Cross-validation, and was further validated against human annotation to measure label reliability. Test results show excellent annotation reliability, with a Krippendorff's Alpha of 0.8070 and an ICC(A,k) of 0.9548. The data scenario with citation and visual-reference masking yielded the best correlation, with a Pearson of 0.9139 and a Spearman of 0.9231, while the data scenario with citation masking alone yielded the lowest prediction error, with an RMSE of 0.1608 and an MAE of 0.1137. Per-zone evaluation shows 99% accuracy in the high and medium similarity zones, but this declines to 43-63% in the low and negative zones, with the lowest confusion-matrix diagonal accuracy at 20.7-25.1%.

***Keywords**: academic plagiarism, IndoBERT, paraphrase, semantic similarity detection, Siamese Bi-encoder.*

KATA PENGANTAR

Assalamu'alaikum Wr. Wb.

Segala puji dan syukur kami panjatkan kepada Allah SWT, Tuhan Yang Maha Esa, atas segala rahmat, karunia, dan petunjuk-Nya yang tiada henti, sehingga penulis mampu menyelesaikan tugas akhir ini dengan baik dan tepat waktu. Tugas akhir ini disusun untuk memenuhi persyaratan guna memperoleh gelar Sarjana Informatika pada Program Studi S1 Informatika Universitas Telkom Surabaya.

Dalam proses penyelesaian studi dan penulisan tugas akhir ini, kami telah menerima banyak dukungan, arahan, dan masukan dari berbagai pihak, baik secara langsung maupun tidak langsung. Dengan penuh rasa terima kasih, kami menyampaikan apresiasi kepada kedua orang tua yang senantiasa memberikan doa, motivasi, dan dukungan tanpa henti. Terima kasih juga kami sampaikan kepada kedua dosen pembimbing yang telah memberikan bimbingan, arahan, dan kesabaran dalam setiap tahap penelitian. Tak lupa kepada rekan-rekan yang selalu memberikan semangat dan dukungan moral selama proses studi dan penulisan ini.

Kami menyadari bahwa tugas akhir ini masih jauh dari kesempurnaan, oleh karena itu, kami mohon maaf atas segala kekurangan, kesalahan, dan ketidaksempurnaan yang ada dalam penulisan ini. Kami sangat terbuka untuk menerima kritik dan saran yang konstruktif guna perbaikan di masa yang akan datang.

Wassalamu'alaikum Wr. Wb.

Penulis

UCAPAN TERIMA KASIH

Dengan ini, penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada pihak-pihak yang telah memberikan dukungan, bimbingan, serta kontribusi dalam penyusunan tugas akhir ini, khususnya kepada:

1. Kedua orang tua tercinta, yang selalu memberikan doa, motivasi, dan dukungan moral tanpa henti sepanjang perjalanan studi penulis. Terima kasih atas segala cinta dan pengorbanan yang tiada terhingga.
2. Ibu Alqis Rausanfita, S.Kom., M.Kom., selaku pembimbing 1 yang telah memberikan dukungan, arahan, dan bimbingan yang sangat berarti selama proses penulisan tugas akhir ini.
3. Bapak Tanzilal Mustaqim, S.Kom., M.Kom., selaku pembimbing 2 yang telah memberikan masukan, kritik konstruktif, dan bimbingan yang sangat berharga dalam menyelesaikan tugas akhir ini.
4. Teman-teman mahasiswa yang telah memberikan semangat, dukungan moral, serta berbagai bantuan, terutama bantuan mental dengan tetap login meski dalam keadaan tidak baik-baik saja

DAFTAR ISI

LEMBAR PENGESAHAN ..... **ii**
LEMBAR PERNYATAAN ORISINALITAS ..... **iii**
ABSTRAK ..... **iv**
ABSTRACT ..... **v**
KATA PENGANTAR ..... **vi**
UCAPAN TERIMA KASIH ..... **vii**
DAFTAR ISI ..... **viii**
DAFTAR TABEL ..... **xi**
DAFTAR GAMBAR ..... **xiii**
DAFTAR LAMPIRAN ..... **xv**
BAB I PENDAHULUAN **1**
1.1. Latar Belakang **1**
1.2. Rumusan Masalah **3**
1.3. Tujuan Penelitian **3**
1.4. Batasan Masalah **3**
1.5. Manfaat Penelitian **4**
1.6. Sistematika Penulisan **4**
BAB II TINJAUAN PUSTAKA **6**
2.1. Penelitian Terdahulu **6**
2.2. *Natural Language Processing* (NLP) **13**
2.3. Plagiasi Sistem **14**
2.4. Tugas Akhir Mahasiswa **14**
2.5. BERT dan IndoBERT **15**
2.6. Arsitektur Siamase Bi-encoder **17**
2.7. Semantic Similarity **18**
2.9. *Cross-validation* **22**
2.10. Evaluasi Model **23**
2.11. Alasan Pemilihan Teori dan Metode **29**

BAB III METODOLOGI PENELITIAN 31
3.1. Alur Penelitian 31
3.2. Alat dan Bahan 31
3.3.1. Pengumpulan Data 33
3.3.2. Pra-Pemrosesan (*preprocessing*) 34
3.3.3. Pembuatan Pairs Dataset Untuk *Fine-Tuning* 37
3.3.4. Pelabelan Dataset 39
3.3.6. Pembagian Data dengan 5-*Fold Cross-validation* 42
3.3.7. Pelatihan IndoBERT 43
3.3.8. Pengujian Model 45
3.3.9. Evaluasi Model 46
3.3.10. Pembangunan Website 48
3.4. Jadwal Penelitian 51
BAB IV HASIL DAN PEMBAHASAN 52
4.1. Implementasi 52
4.1.1 Pengumpulan data 52
4.1.2 Eksraksi data Bab II 52
4.1.3 Pembersihan dan Segmentasi Teks 55
4.1.4 Pembuatan Pasangan 3 Versi Dataset untuk Fine-Tuning 56
4.1.5 Pelabelan Otomatis Dataset 57
4.1.6 Pembagian Data dengan 5-*Fold Cross-validation* 78
4.1.7 Implementasi Fine-Tuning IndoBERT 79
4.1.8 Implemetasi Sistem Deteksi Plagiarisme 80
4.2. Validasi Data 87
4.2.1. Implementasi dan Hasil Validasi Data 87
4.2.2. Kesimpulan Validasi Data 92
4.3. Hasil Pengujian 93
4.3.1. Hasil Pengujian *Hyperparameter* Data S1 94
4.3.2. Hasil Pengujian *Hyperparameter* Skenario S1-mc 96
4.3.3. Hasil Pengujian *Hyperparameter* Skenario S1-mca 98
4.3.4. Performa Terbaik Antar Skenario 100
4.3.5. Evaluasi Kinerja Model setiap Zona 101
4.4. Pembahasan dan Analisis 103
4.4.1. Analisis Performa Model Keseluruhan 103
4.4.2. Analisis Faktor Performa dan Generalisasi Model 106

4.4.3. Analisis Performa Model pada Setiap Zona Kemiripan 108

4.4.4. Analisis Overprediction 111

BAB V KESIMPULAN DAN SARAN 126

5.1. Kesimpulan 126

5.2. Saran 127

DAFTAR PUSTAKA 128

LAMPIRAN 132

DAFTAR TABEL

Tabel II. 1 Penelitian Terdahulu 1 6
Tabel II. 2 Penelitian Terdahulu 2 8
Tabel II. 3 Penelitian Terdahulu 3 9
Tabel II. 4 Penelitian Terdahulu 4 11
Tabel II. 5 Penelitian Terdahulu 5 12
Tabel III.1 Spesifikasi Alat dan Bahan Penelitian 32
Tabel III. 2 Skenario Perlakuan Teks 35
Tabel III.3 Hasil Data Setelah Segmentasi 36
Tabel III. 4 Tingkat Parafrase 37
Tabel III. 5 Prompt Parafrase 38
Tabel III. 6 Tabel Struktur Data Fine-Tuning 39
Tabel III. 7 Ringkasan Rancangan Validasi Data 41
Tabel III.8 Tabel Ringkasan Fine Tuning Model 45
Tabel III. 9 Tabel Pengujian Model 45
Tabel III. 10 Jadwal Pelaksanaan 51
Tabel IV. 1 Konfigurasi Ekstraksi Teks 52
Tabel IV. 2 Kode Program ekstraksi 53
Tabel IV. 3 Kode Program Cross-Page Continuation 53
Tabel IV. 4 Konfigurasi Segmentasi 55
Tabel IV. 5 Statistik Distribusi Data setiap Skenario 56
Tabel IV. 6 Kode Program Implementasi Batch Similarity Scoring 57
Tabel IV. 7 Contoh Hasil Data S1 59
Tabel IV. 8 Contoh hasil Data S1-MC 64
Tabel IV. 9 Contoh Hasil Data S1-MCA 72
Tabel IV. 10 Kode Program Implementasi pembagian *fold* dan validasi 78
Tabel IV. 11 Distribusi Pembagian Data 79
Tabel IV. 12 Kode Program Implementasi Forward Pass dan Loss 80
Tabel IV. 13 Hasil Inter-Rater Reliability 88
Tabel IV. 14 Disagreement Tertinggi 89
Tabel IV. 15 Rata-Rata 5 Anotator 90
Tabel IV. 16 Hasil Metriks Evaluasi antara Label dan Anotator 90

Tabel IV. 17 Ringkasan Hasil Validasi Dataset 93
Tabel IV. 18 Hasil Pengujian *Hyperparameter* Skenario S1..... 94
Tabel IV. 19 Hasil setiap *Fold* Data S1 95
Tabel IV. 20 Hasil Pengujian *Hyperparameter* S1-mc..... 96
Tabel IV. 21 Rincian Hasil Setiap *Fold* Konfigurasi Terbaik S1-mc 97
Tabel IV. 22 Hasil Pengujian *Hyperparameter* Skenario S1-mca..... 98
Tabel IV. 23 Rincian Hasil Setiap *Fold* Konfigurasi Terbaik S1-mca 99
Tabel IV. 24 Konfigurasi Terbaik Seluruh Skenario 100
Tabel IV. 25 Hasil Evaluasi Setiap Zona..... 101
Tabel IV. 26 perbandingan hasil pengujian dokumen pada 3 skenario 117

DAFTAR GAMBAR

Gambar II. 1 Arsitektur BERT 16
Gambar II. 2 Arsitektur SBERT 17
Gambar II. 3 Skema *Cross-validation* 23
Gambar III. 1 Alur Penelitian 31
Gambar III. 2 Alur Perancangan Sistem 33
Gambar III. 3 Alur Pra-pemrosesan Data 34
Gambar III. 4 Alur Pembuatan Pasangan Dataset 37
Gambar III. 5 Skema 5-*Fold Cross-validation* Berbasis Dokumen 43
Gambar III.6 Arsitektur Simiase Bi-Encoder 43
Gambar III.7 Alur Pelatihan Model 44
Gambar III. 8 Tampilan Antarmuka 1 49
Gambar III. 9 Tampilan Antarmuka 2 50
Gambar IV. 1 Hasil Ekstraksi Dokumen 54
Gambar IV. 2 Tampilan Website 81
Gambar IV. 3 Tampilan Hasil Analisis 82
Gambar IV. 4 Tampilan Statistik Dokumen dan Distribusi zona 83
Gambar IV. 5 Tampilan top5 setiap paragraf 84
Gambar IV.6 Alur Website 84
Gambar IV. 7 Distribusi penilaian tiap anotator 87
Gambar IV. 8 Matriks Korelasi Pearson Antar Anotatora 88
Gambar IV. 9 Visualisasi Hasil dan Bland-altman Plot 91
Gambar IV. 10 Confusion Matrix S1 102
Gambar IV. 11 Confusion Matrix S1-mca 102
Gambar IV. 12 Confusion Matrix S1-mc 102
Gambar IV. 13 Visualisasi Perbandingan Kinerja seluruh Skenario 104
Gambar IV. 14 Visualisasi Hubungan Trade-off Pearson dan RMSE 105
Gambar IV. 15 Heatmap *Hyperparameter* Berdasarkan Nilai Pearson 107
Gambar IV. 16 Learning Curve Rata-rata 5-*Fold* pada Konfigurasi Terbaik 107
Gambar IV. 17 Stabilitas Nilai Pearson pada Setiap *Fold* untuk Konfigurasi Terbaik 108

Gambar IV. 18 Perbandingan Nilai F1-Macro dan MAE pada Setiap Zona Kemiripan..... 109
Gambar IV. 19 Scatter Plot Nilai Aktual dan Prediksi 111
Gambar IV. 20 Distribusi Residual Hasil Prediksi..... 112
Gambar IV. 21 Hasil Dokumen Pada Skenario S1..... 115
Gambar IV. 22 Hasil Dokumen Pada Skenario S1-MC 115
Gambar IV. 23 Hasil Dokumen Pada Skenario S1-MCA 116
Gambar IV. 24 Ringkasan setiap Subbab Skenario S1 118
Gambar IV. 25 Rinkasan setiap Subbab Skenarip S1-MC..... 118
Gambar IV. 26 Ringkasan setiap Subbab Skenario S1-MCA..... 119
Gambar IV. 27 rincian segmen2.1 skenario S1 120
Gambar IV. 28 rincian segmen2.1 skenario S1-MC 120
Gambar IV. 29 Rincian segmen2.1 skenario S1-MCA 122

DAFTAR LAMPIRAN

Lampiran 1. Kode Program Ekstraksi dan Segmentasi 132
Lampiran 2. Kode Program Pelatihan Model 134
Lampiran 3. Kode Program Evaluasi 138
Lampiran 4. Kode Program Validasi Data Anotator 140
Lampiran 5. Cuplikan data Validasi 5 Anotator 142

BAB I
PENDAHULUAN

1.1. Latar Belakang

Kemajuan teknologi informasi dan meningkatnya akses terhadap literatur digital telah membawa perubahan signifikan dalam proses penulisan karya ilmiah di perguruan tinggi. Repositori institusi, jurnal daring, dan mesin pencari akademik mempermudah mahasiswa memperoleh sumber referensi secara cepat dan luas. Namun, kemudahan ini juga memunculkan tantangan serius terhadap integritas akademik, karena akses informasi yang tidak terbatas serta pemanfaatan teknologi digital, termasuk kecerdasan buatan, berpotensi meningkatkan praktik plagiarisme apabila tidak diimbangi dengan pemahaman etika akademik yang memadai (Amalina & Ardiansyah, 2025).

Dalam penulisan tugas akhir, Bab II (Tinjauan Pustaka) merupakan bagian yang paling rentan terhadap plagiarisme karena berisi kumpulan teori, definisi, dan hasil penelitian terdahulu yang secara alami memiliki tingkat kemiripan antar dokumen. Penelitian terhadap 79 proposal tugas akhir mahasiswa menunjukkan bahwa rata-rata indeks kemiripan Bab II mencapai 71%, yang mengindikasikan tingginya potensi plagiarisme pada bagian ini (Oktapiani dkk., 2023). Kerentanan Bab II diperkuat oleh rendahnya pemahaman mahasiswa mengenai teknik parafrase yang benar serta kewajiban mencantumkan atribusi sumber secara tepat (Budiman & Widjaja, 2020).

Selain itu, banyak mahasiswa mengalami kesulitan dalam menyusun tinjauan pustaka yang koheren dan terintegrasi. Penyusunan Bab II menuntut kemampuan untuk mengaitkan berbagai teori dan penelitian terdahulu secara logis dan orisinal. Ketika keterampilan ini belum dikuasai, mahasiswa cenderung menyalin atau merangkum teks dari sumber yang ada, sehingga meningkatkan risiko plagiarisme akademik (Risparyanto, 2020). Faktor tekanan waktu, keterbatasan bimbingan, serta ketergantungan pada sumber daring yang mudah diakses namun kurang terverifikasi juga memperburuk permasalahan tersebut (Hermawan, 2017).

Di sisi lain, sistem deteksi plagiarisme yang umum digunakan di lingkungan akademik masih banyak mengandalkan pendekatan berbasis pencocokan kata (lexical matching) seperti n-gram dan kemiripan berbasis string. Pendekatan ini efektif untuk mendeteksi plagiarisme literal, tetapi memiliki keterbatasan dalam mendeteksi plagiarisme berbasis parafrase, perubahan struktur kalimat, dan penggunaan sinonim. Berbagai penelitian menunjukkan bahwa metode leksikal kurang mampu menangkap kesamaan makna antar teks yang secara semantik mirip namun berbeda secara leksikal (Clough & Stevenson, 2011).

Pendekatan kemiripan semantik menjadi semakin penting dalam pengembangan sistem deteksi plagiarisme modern. Pendekatan ini berfokus pada pemahaman makna dan konteks teks, bukan hanya kesamaan kata. Model bahasa berbasis transformer seperti BERT telah terbukti mampu menghasilkan representasi semantik yang kuat dan unggul dalam tugas *semantic textual similarity* dibandingkan metode tradisional (Reimers & Gurevych, 2019). Representasi berbasis embedding memungkinkan pengukuran kemiripan makna secara lebih akurat menggunakan cosine similarity.

Untuk konteks Bahasa Indonesia, penggunaan model bahasa multibahasa belum sepenuhnya optimal karena perbedaan karakteristik linguistik. IndoBERT**,** sebagai model pralatih khusus Bahasa Indonesia, terbukti memberikan performa yang lebih baik dalam memahami konteks linguistik lokal dibandingkan model umum (Wilie dkk., 2020). Dengan menerapkan arsitektur *Siamese Bi-Encoder*, IndoBERT dapat memproses dua segmen teks secara paralel dan menghasilkan embedding yang konsisten, sehingga sangat sesuai untuk tugas pengukuran kemiripan semantik antar segmen dokumen (Reimers & Gurevych, 2019; Shadiqi, 2019).

Berdasarkan permasalahan tersebut, penelitian ini mengusulkan pengembangan sistem deteksi kemiripan semantik pada Bab II tugas akhir dengan memanfaatkan *fine-tuning* IndoBERT berbasis *Siamese Bi-Encode**r***, pembuatan dataset parafrase bertingkat**.** Pendekatan ini diharapkan mampu mengatasi keterbatasan metode berbasis pencocokan kata, meningkatkan akurasi deteksi kemiripan semantik, serta memberikan kontribusi nyata dalam menjaga integritas akademik di lingkungan perguruan tinggi.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana implementasi sistem deteksi kemiripan semantik pada Bab II tugas akhir berbahasa Indonesia dengan memanfaatkan model IndoBERT yang di-*fine-tune* dengan dataset akademik menggunakan arsitektur Siamese Bi-Encoder?
2. Bagaimana evaluasi sistem deteksi kemiripan semantik pada Bab II tugas akhir berbahasa Indonesia dengan memanfaatkan model IndoBERT yang di-*fine-tune* dengan dataset akademik menggunakan arsitektur Siamese Bi-Encoder?

1.3. Tujuan Penelitian

Adapun tujuan dari penelitian ini sebagai berikut:

1. Merancang dan membangun sistem deteksi kemiripan semantik pada Bab II tugas akhir berbahasa Indonesia dengan memanfaatkan model IndoBERT yang di-*fine-tune* menggunakan dataset teks akademik dan menerapkan arsitektur Siamese Bi-Encode*r* untuk menghasilkan representasi embedding semantik.
2. Mengevaluasi kinerja model IndoBERT hasil *fine-tuning* dalam memprediksi tingkat kemiripan semantik antar segmen Bab II tugas akhir secara objektif dan terukur menggunakan skema *5-Fold Cross-validation* berbasis dokumen dengan metrik evaluasi *Pearson Correlation*, RMSE, dan MAE.

1.4. Batasan Masalah

1. Objek penelitian dibatasi pada Bab II (Tinjauan Pustaka) tugas akhir
2. Dataset yang digunakan hanya pada 45 dokumen tugas akhir mahasiswa informatika Telkom University Surabaya
3. Implementasi terbatas pada analisis teks berbahasa Indonesia.
4. Pasangan kalimat untuk data latih dibentuk menggunakan metode parafrase otomatis yang dihasilkan oleh GPT.
5. Skor Label data latih di hasilkan menggunakan penilaian model MPNet

1.5. Manfaat Penelitian

Adapun manfaat dari penelitian ini sebagai berikut:

1. Memberikan manfaat dalam mengetahui kinerja model IndoBERT hasil fine-tuning dataset akademik dalam memprediksi tingkat kemiripan semantik antar segmen Bab II tugas akhir
2. Memberikan manfaat sebagai alat bantu bagi dosen dan pengelola tugas akhir dalam melakukan pemeriksaan kemiripan dokumen secara lebih akurat dan efisien.
3. Memberikan manfaat sebagai dasar pengembangan sistem deteksi plagiarisme berbasis makna pada dokumen akademik Bahasa Indonesia, serta sebagai referensi bagi penelitian selanjutnya yang mengembangkan model, dataset, atau cakupan dokumen yang lebih luas.

1.6. Sistematika Penulisan

Penelitian ini disusun secara sistematis menjadi beberapa bab yang memuat uraian sebagai berikut:

1. Bab I Pendahuluan

   Bab ini memuat latar belakang penelitian, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan yang menjelaskan arah dan ruang lingkup penelitian secara umum.
2. Bab II Tinjauan Pustaka

   Bab ini berisi landasan teori dan kajian penelitian terdahulu yang relevan dengan topik penelitian. Pembahasan mencakup konsep plagiarisme akademik, kemiripan semantik, model bahasa berbasis transformer, IndoBERT, arsitektur Siamese Bi-Encoder, serta metode evaluasi yang digunakan sebagai dasar dalam pengembangan sistem.
3. Bab III Metodologi Penelitian

   Bab ini menjelaskan tahapan dan metode penelitian yang digunakan, mulai dari pengumpulan data, persiapan dan segmentasi teks, pembuatan dataset pelatihan, perancangan arsitektur model, proses fine-tuning IndoBERT,

hingga perhitungan kemiripan semantik dan skema evaluasi menggunakan 5-*Fold Cross-validation* berbasis dokumen.

4. Bab IV Hasil dan Pembahasan

   Bab ini menyajikan hasil implementasi sistem, validasi dataset, hasil pelatihan dan evaluasi model, serta analisis terhadap performa model yang dikembangkan. Pembahasan mencakup implementasi sistem deteksi kemiripan semantik, pengaruh strategi *preprocessing* dan *hyperparameter*, analisis performa pada setiap zona kemiripan, analisis kecenderungan *overprediction*, serta keterbatasan penelitian berdasarkan hasil pengujian yang telah dilakukan.

5. Bab V Kesimpulan dan Saran

   Bab ini berisi kesimpulan yang diperoleh berdasarkan hasil implementasi dan evaluasi penelitian sebagai jawaban atas rumusan masalah yang telah ditetapkan. Selain itu, bab ini juga memuat saran yang ditujukan untuk pengembangan penelitian maupun implementasi sistem pada penelitian selanjutnya.